

INTRODUCTION

Doğal dil işleme (NLP), son yıllarda yapay zekâ alanındaki gelişmelerle birlikte hızla ilerleyen ve metin verisinin analiz edilmesini mümkün kılan önemli bir araştırma alanıdır. Özellikle büyük dil modellerinin gelişmesiyle birlikte, yapay zekâ tarafından üretilen metinlerin kalitesi önemli ölçüde artmış ve bu metinlerin insan tarafından yazılan metinlerden ayırt edilmesi giderek zorlaşmıştır. Bu durum; akademik dürüstlük, içerik güvenilirliği ve bilgi doğruluğu gibi kritik alanlarda yeni problemlerin ortaya çıkmasına neden olmuştur.

Bu çalışmanın temel amacı, insan tarafından üretilen metinler ile yapay zekâ tarafından oluşturulan metinleri otomatik olarak ayırt edebilen bir makine öğrenmesi modeli geliştirmektir. Bu doğrultuda, Kaggle platformunda yer alan “AI vs Human Text” veri seti kullanılarak kapsamlı bir analiz gerçekleştirilmiştir. Çalışma kapsamında veri ön işleme, özellik çıkarımı ve model geliştirme aşamaları sistematik bir şekilde ele alınmış; Logistic Regression, Multinomial Naive Bayes ve Linear Support Vector Machine (SVM) algoritmaları kullanılarak farklı modeller oluşturulmuştur.

Ayrıca, geliştirilen modeller yalnızca doğruluk (accuracy) metriği ile değil; precision, recall ve F1-score gibi daha detaylı performans ölçütleri ile değerlendirilmiştir. Bunun yanı sıra, model kararlarının daha iyi anlaşılabilmesi için açıklanabilir yapay zekâ (Explainable AI) yöntemlerinden biri olan LIME analizi uygulanmıştır. Bu sayede, modellerin hangi özelliklere dayanarak karar verdiği incelenmiş ve yorumlanabilirliği artırılmıştır.

Bu çalışma, yapay zekâ tarafından üretilen içeriklerin tespit edilmesine yönelik etkili yöntemlerin geliştirilmesine katkı sağlamayı ve metin sınıflandırma problemlerine yönelik karşılaştırmalı bir analiz sunmayı amaçlamaktadır.

RELATED WORK


Yapay zekâ tarafından üretilen metinlerin tespiti, büyük dil modellerinin (LLM) yaygınlaşmasıyla birlikte NLP araştırmalarının en aktif alanlarından biri haline gelmiştir. Bu alanda öncü çalışmalardan biri olan Gehrmann, Strobel ve Rush (2019), GPT-2 çıktılarını istatistiksel yöntemlerle tespit eden GLTR aracını önermiş ve insan tespit oranını %54'ten %72'ye çıkarabildiğini göstermiştir. Jawahar, Abdul-Mageed ve Lakshmanan (2020), COLING 2020'de yayımlanan kapsamlı derleme çalışmalarında mevcut tespit yöntemlerinin derinlemesine hata analizini gerçekleştirmiş ve alana yönelik araştırma yönleri ortaya koymuştur. Mitchell ve ark. (2023) ise ICML 2023'te sundukları DetectGPT yöntemiyle, ayrı bir sınıflandırıcı eğitimi gerektirmeden LLM çıktılarının sıfır-çekim (zero-shot) yaklaşımla tespit edilebildiğini göstermiştir. Tang, Chuang ve Hu (2024), Communications of the ACM dergisinde yayımlanan çalışmalarında bu alandaki yöntemleri kapsamlı biçimde değerlendirmiş; kural tabanlı ve istatistiksel yaklaşımların daha güçlü LLM'lere karşı hızla sınırlarına ulaştığını ve tespit sistemlerinin model gelişimine paralel olarak sürekli güncellenmesi gerektiğini vurgulamıştır.

Metin sınıflandırma görevlerinde TF-IDF tabanlı özellik çıkarımının Lojistik Regresyon, Naive Bayes ve Lineer SVM gibi klasik algoritmalarla birlikte kullanımı, literatürde uzun süredir etkin bir yaklaşım olarak belgelenmiştir. Salton ve Buckley (1988) tarafından önerilen TF-IDF yöntemi, kelime önem ağırlıklandırmasının temelini oluşturmakta; Joachims (1998) ise yüksek boyutlu metin uzaylarında Lineer SVM'nin üstün ayrıştırma gücünü deneysel olarak ortaya koymaktadır. Rennie ve ark. (2003) Naive Bayes modelindeki sıfır olasılık (zero-probability) problemini gidermek için Laplace Düzleştirme'nin önemini vurgulamıştır. Bu yaklaşımın AI metin tespitindeki güncelliğini destekler nitelikte, Zain ve ark. (2025), TF-IDF ve Lineer SVM kombinasyonunun haber makalelerinde yapay zekâ tarafından üretilen içeriği tespit etmede güçlü bir temel oluşturduğunu göstermiş; bu sonuç, mevcut çalışmada Lineer SVM ile elde edilen %99,90 doğruluk oranıyla örtüşmektedir.

Model kararlarının yorumlanabilirliği ve sınıf dengesizliği, bu çalışmanın iki önemli metodolojik boyutunu oluşturmaktadır. Ribeiro, Singh ve Guestrin (2016) tarafından önerilen LIME (Local Interpretable Model-agnostic Explanations) yöntemi, herhangi bir modelin bireysel tahminlerini mimariden bağımsız biçimde açıklamakta ve metin sınıflandırma başta olmak üzere pek çok alanda yaygın biçimde kullanılmaktadır. Chawla ve ark. (2002) ise sınıf dengesizliğinin modeli çoğunluk sınıfa yönltebileceğini ve bu nedenle yalnızca Accuracy yerine Precision, Recall ve F1-Score gibi ek metriklerin kullanılmasının gerekli olduğunu göstermiştir. Mevcut çalışmada da her iki ilke benimsenmiş; stratify parametresiyle dengeli eğitim-test bölünmesi yapılmış, F1-Score odaklı değerlendirme tercih edilmiş ve Lineer SVM modeli üzerinde LIME analizi uygulanmıştır.


DATASET DESCRIPTION

Bu projede insan tarafından üretilen metinler ile yapay zeka tarafından üretilen metinleri ayırt etmek amacıyla Kaggle platformunda bulunan AI vs Human Text veri seti kullanılmıştır. Veri seti toplam 487235 veriden oluşmakta olup her veri için “text” sütunu altında metin ve “generated” sütunu altında etiket bilgisi yer almaktadır. Veri seti AI ve Human olmak üzere iki sınıftan oluşmaktadır. Sınıf bazlı dağılım incelemelerimiz sonucunda Human sınıfında 305797 veri, AI sınıfında 181437 veri olduğu gözlemlenmiştir. Ayrıca veri setinin dengesiz bir dağılıma sahip olduğu da anlaşılmıştır. Veri setinde Human sınıfının daha ağır bastığı gözlemlenmiştir.



Yapılan analizler sonucunda veri setindeki metin uzunluğunun ortalama 393 kelimeden oluştuğu, 168 kelimelik sapmaların olduğu yani veri setinde çeşitliliğin bulunduğu gözlemlenmiştir. En uzun metnin 1668 kelime uzunluğuna sahip olduğu veri setinde kelime içermeyen boş satırların bulunduğu tespit edilmiştir. Metinlerin %50 'sinin uzunluğunun 363 kelime altında olduğu gözlenirken, %75 'inin ise 471 kelime altında olduğu görülmüştür. Bu durum bize veri setinin büyük çoğunluğunun 300-500 kelime arasında olduğunu göstermiştir. Sınıf bazlı ortalama kelime sayısı analizi sonucunda Human sınıfı için ortalama kelime sayısı 421, AI sınıfı için ortalama kelime sayısı 344 olarak hesaplanmıştır. Bu durum veri setinde insan tarafından üretilen metinlerin AI tarafından üretilen metinlere göre daha uzun yapıda olduğunu göstermektedir.

İstatistik	Değer
Toplam Metin Sayısı	487235
Genel Bulunan Ortalama Kelime Sayısı	393
İnsan Metinlerinin Ortalama Kelime Sayısı	421
AI Metinlerinin Ortalama Kelime Sayısı	344



Veri setinden her iki sınıf için de eşit veri (Human için 250 örnek, AI için 250 örnek) içeren bir örneklem oluşturulmuştur. Bu veri seti GitHub repository de dataset_sample.csv olarak yer almaktadır. Veri seti hakkında daha iyi bir izlenim elde edilebilmesi açısından veri setinden seçilen Human ve AI sınıfları için örnek metinler aşağıda yer almaktadır:

Human: In my opinion I think that we shouldn't continue with elector college. I think we should change it to election by popular vote for president of the un...

AI: Dear Senator, I am writing to you today to express my support for abolishing the Electoral College and electing the president of the United States by...

Bu iki örnek veri seti hakkında bir çıkarımda bulunulmasını sağlamaktadır. İnsan tarafından oluşturulan metinler daha öznel ve günlük bir dil içerirken, AI tarafından oluşturulan metinler daha resmi ve dil bilgisine uygun bir dil içermektedir.

METHODOLOGY

Bu çalışmada veri ön işleme (data preprocessing) aşamasından başlanarak sırasıyla şu adımlar izlenmiştir:

1. Veri Ön İşleme (Data Preprocessing)

Bu aşamada veri setindeki metinler sonraki aşamalar için daha uygun ve işlenebilir hale getirilmek için belli ön işleme adımlarından geçirilmiştir. Öncelikle veri setinde kelime frekans analizi yapılmıştır. Bu analiz sonucunda en sık kullanılan ilk 30 kelime sıralaması elde edilmiştir.

Bu analiz ile birlikte NLTK stop words listesinde yer almayan “people” ve “students” kelimelerinin veri setinde sıklıkla geçtiği gözlemlenmiştir. Bu iki kelimenin metnin AI mı, İnsan mı tarafından yazıldığı hakkında bilgi vermediği göz önünde bulundurularak standart NLTK stop words listesine dahil edilmiştir. Ayrıca NLTK stop words listesinde bulunan “would” kelimesi resmi bir anlam taşıdığı için ve AI tarafından kullanılabileceği göz önünde bulundurularak listeden çıkarılmıştır. Son olarak listede yer alan “no” ve “not” kelimeleri de AI tarafından tercih edilen kelimeler olduğundan listeden çıkarılmıştır. Bunu daha iyi açıklamamız gerekirse, insanlar tarafından oluşturulan metinlerde karşımıza kısaltmalar oldukça sık çıkabilmektedir. Çünkü insanlar genel olarak kısaltmaları tercih etmektedir. Ama AI tarafına baktığımızda, AI tarafından oluşturulan metinlerde karşımıza kısaltmaların uzun formları çıkmaktadır. Örneğin bir AI, I do not... biçiminde bir ifade kullanırken insan I don’t şeklinde bir ifade kullanır. Sonuç olarak bu kelimeler metin insana mı ait AI ‘mı ait bu konuda bilgi veren anahtar kelime özelliği taşımaktadır. Bu analiz işlemi sonrası sırası ile ön işleme adımları uygulanmıştır. İlk olarak lowercasing işlemi uygulanarak veri setindeki metinler küçük harflere dönüştürülmüştür. Bu aşama ile modele metin içindeki “Apple” ve “apple” gibi ifadelerin aslında aynı olduğu gösterilerek modelin kafasının karışması önlenmiştir. Sonraki aşamada noktalama işareti temizliği yapılmıştır. Bu aşama ile “apple” ve “apple,” gibi ifadelerin aynı iki ifade olduğu modele gösterilmiş ve vektörleştirme aşamasında noktalama işaretlerinin de vektörleştirilmesi ve gürültü oluşumu önlenmiştir. Sonraki aşamada tokenization işlemi ile metinler kelimelere ayrılmıştır. Bu aşama ile vektörleştirme aşaması ve stop word işlemi mümkün hale gelmiştir. Son aşamada stop word temizliği uygulanmıştır. Bu aşama ile tek başına bir anlamı olmayan, gereksiz kelimeler temizlenerek modelin asıl önemli olan kelimelere odaklanabilmesi ve daha iyi tahminlerde bulunabilmesi sağlanmıştır.

Veri Setinden Bir Örneğin Ön İşleme Öncesi ve Sonrası :

Öncesi: Cars. Cars have been around since they became famous in the 1900s, when Henry Ford created and built the first ModelT. Cars have played a major role i...

Sonrası: cars cars around since became famous henry ford created built first modelt cars played major role every day lives since starting question limiting car...

2. Özellik Çıkarımı (Feature Extraction)

Modelin veriyi okuyup işleyebilmesi için sayısallaştırılması gerekmektedir. Bu aşamada veri setindeki kelimeler TF-IDF (Term Frequency-Inverse Document Frequency) vektörleştirme metodu ile metindeki önemlerine göre sayısallaştırılmıştır. Vektörleştirme aşamasında kullandığımız max_feature=20000 değişkeni ile metindeki en çok ayırt edici olan 20000 kelime kullanılarak bir sözlük oluşturulmuş ve bu sözlük ile vektörleştirme yapılmıştır. Ek olarak ngram_range (1,2) yapısı kullanılarak hem tekil hem de ikili kelime grupları sözlüğe dahil edilmiş, modelin AI ve Human sınıflarında kullanılan ikili kelime gruplarını da görmesi ve öğrenmesi sağlanmıştır. Sözlük tanımlandıktan sonra TF-IDF metodundaki matematiksel işlemler gerçekleştirilmiştir. Sözlükte yer alan her bir kelime için metinler incelenmiş, geçip geçmediğine göre bir analiz yapılmış ve analiz sonucunda bir matris elde edilmiştir. Bu matrise “Seyrek Matris (Sparse Matrix)” denmektedir çünkü metinde yer alan ama sözlükte yer almayan her bir kelimenin matriste değeri “0” olmaktadır.

3. Model Geliştirme (Model Development)

Bu aşamada model eğitime hazır hale getirilmiş veriler kullanılarak sırasıyla “Logistic Regression”, “Multinomial Naive Bayes” ve “Linear SVM” modelleri ile eğitimler gerçekleştirilmiştir. Eğitim öncesi veri seti stratify yapısı kullanılarak her iki kısımda da AI ve Human sınıflarından eşit örnek yer alacak şekilde “%80” train ve “%20” test olmak üzere ikiye ayrılmıştır. Logistic Regression modeli ile eğitim sürecine başlanılmıştır. Veri seti büyük olduğundan ve Logistic Regression modelinin hızlı sonuç vermesini istediğimizden model kurulumu sırasında “solver=saga” tanımlaması yapılmıştır. Eğitim sonucunda genel doğruluk “%99,59” olarak gözlemlenmiştir. Model veri seti dışında iki metin ile test edilmiştir. Test işlemi esnasında model eğitimi öncesi veri setine uygulanan ön işleme adımları sırasıyla uygulanarak test verileri modele uygun hale getirilmiştir. Bu işlem ile modelin eğitim verisini ezberleyip ezberlemediği kontrol edilmiştir.

Sonraki aşamada “Multinomial Naive Bayes” modeli ile eğitim gerçekleştirilmiştir. Model kurulumu sırasında alpha değeri 0.1 olarak tanımlanmıştır. Naive Bayes olasılık çarpımına dayanan bir algortımadır. Sözlükte yer almayan ama metinde geçen bir kelime olduğunda o kelime “0” değerini almakta ve çarpım direk sıfırlanmaktadır. Dolayısıyla model diğer kelimeleri göz ardı etmiş olmakta ve hatalı sonuçlar üretebilmektedir. Bu problem “Zero Probability” olarak adlandırılmaktadır. Tanımlanan alpha değeri ile “Laplace Smoothing” yapılmakta yani direk kelimeye “0” vermek yerinde tanımlanan alpha değeri verilmektedir. Alpha değeri genellikle küçük tercih edilmektedir böylece veri setinin

büyük oranda değişmesi ve modelin tahminlerinin büyük oranda etkilenmesi engellenmektedir. Eğitim sonucunda genel doğruluk “%97,14” olarak gözlemlenmiştir. Model veri seti dışında iki metin ile test edilmiştir. Bu işlem ile model de overfitting var olup olmadığı incelenmiştir.

Son aşamada standart SVM’e göre büyük veri setlerinde daha hızlı olduğundan “Linear SVM” ile eğitim gerçekleştirilmiştir. Eğitim sonucunda genel doğruluk “%99,90” olarak gözlemlenmiştir. Model veri seti dışında iki metin ile test edilmiştir. Test işlemi sırasında önceki modellerde kullanılan predict_proba yapısı yerine decision function yapısı kullanılmıştır.

4. Model Değerlendirmesi (Model Evaluation)

Model başarısını ölçmek için genel doğruluk ile birlikte modelin hata payını ölçen ve sınıf bazlı hassasiyetini gösteren detaylı metrikler üzerinden de değerlendirme yapılmıştır:

Precision: Modelin Human dediği metinlerin ne kadarı gerçekten Human, bunu gösteren metriktir. Yanlış pozitifler (Human olan metne AI denmesi gibi.) yüksek maliyetli olduğundan kritik bir öneme sahiptir.

Recall: Modelin gerçekten insan tarafından yazılan (Human) ya da AI tarafından yazılan metinlerin ne kadarını yakalayabildiğini gösteren metriktir.

F1-Score: Precision ve Recall metriklerinin harmonik ortalamasıdır. Veri setinde sınıflar arası dengesizlik olan durumlarda modelin genel başarısını en iyi gösteren metriktir. Bu çalışmada kullanılan veri setinde de AI ve Human sınıfları arasında dengesizlik olduğundan bu metrik kritik bir öneme sahiptir.

Confusion Matrix: Confusion Matris’te satırlar ve sütunlardan biri gerçek sınıfı diğeri modelin tahminin göstermektedir. Bu matris ile modelin hangi sınıfları birbirine karıştırdığı, hangi sınıflarda ne kadar hatalı tahmin yaptığı görülebilmektedir.

Feature Importance Analysis (Özellik Önemi Gösteren Analiz): En yüksek doğruluğun elde edildiği Linear SVM modeli üzerinde gerçekleştirilmiş, modelin bir metne AI ve Human demesinde etkili olan ilk 20 kelime sıralanmıştır.

Error Analysis (Hata Analizi): Modellerin her biri için toplam hatalı tahmin sayısı, hatalı metinlerin kaçında AI’a Human denildiği, kaçında Human’a AI denildiği hesaplanmıştır. Ardından modellerin hatalı tahminde bulunduğu ilk on metin ve güven skorları listelenerek incelenmiştir. Son olarak üç modelinde ortak olarak hatalı tahminde bulunduğu metin sayısı hesaplanmış ve ilk beş metin incelenmiştir.

Açıklanabilirlik (LIME) Analizi: Modellerin sayısal başarısının değerlendirilmesine ek olarak verdiği kararların mantığı da incelenmiştir. LIME (Local Interpretable Model-agnostic Explanations) yöntemi ile gerçekleştirilmiştir. Bu yöntem modelin bir metne neden AI veya Human dediğinin metin içerisindeki anahtar kelimelerin ağırlıkları ile görselleştirilmesidir. Bu işlem için en yüksek başarı elde edilen Linear SVM modeli kullanılmış olup üç modelin de hatalı tahmin yaptığı iki metin incelenmiştir.

EXPERIMENTS

Bu çalışmada deneyler Google Colab T4 GPU üzerinde gerçekleştirilmiştir. Kullanılan temel kütüphaneler aşağıdaki gibidir:

- Google.colab.drive: Veri setini Drive'dan okumak ve modelleri Drive'a kaydedebilmek için kullanılmıştır.
- Matplotlib.pyplot: Model performans grafiklerini (confusion matrix, precision-recall gibi) ve veri analiz sonuçlarını görsel ve daha anlaşılır şekilde sunmak için kullanılmıştır.
- Pandas: Veriyi tablo yapısında işlemek için (DataFrame), sütunları yönetmek ve istatistikleri hesaplayabilmek için kullanılmıştır.
- seaborn (as sns): Matplotlib üzerine inşa edilmiştir. Daha estetik grafikler çizmek için kullanılmıştır.
- Re: Metin içerisindeki belli ifadeleri (sayılar, noktalama işaretleri, linkler gibi) bulmak ve değiştirmek için kullanılan bir kütüphanedir. Bu çalışmada veri ön işleme kısmındaki veri temizliği aşamasında kullanılmıştır.
- from collections import Counter: Bir liste veya veri seti içindeki elemanların kaç kez tekrar ettiğini sayar. Veri setindeki sık kullanılan kelimelerin analizinde kullanılmıştır.
- nlTK ve nlTK.corpus.stopwords: Etkisiz eleman (stop word) listesini projeye dahil etmek için kullanılmıştır.
- sklearn.feature_extraction.text.TfidfVectorizer: Ham metin verilerini modellerin işleyebileceği ve bilgisayarın anlayabileceği TD-IDF Matrisine (sayısal vektörler) dönüştürmek için kullanılmıştır.
- Joblib: Modelleri ve TF-IDF vektörleştiricisini Google Drive'a kaydetmek ve ileri de tekrardan kullanabilmek için kullanılmıştır.
- Numpy: Diziler (array) üzerinde hızlı hesaplamalar yapabilmek ve matematiksel işlemleri gerçekleştirebilmek için kullanılmıştır.
- Sklearn(Scikit-learn): Python programlama dili için geliştirilen en kapsamlı kütüphanedir. Bu çalışmada veri seti analizinden model eğitime ve model performans değerlendirmesine kadar tüm süreçler bu kütüphane üzerinde inşa edilmiştir.
- sklearn.model_selection.train_test_split: Veri setini modelin eğitiminde kullanılan eğitim seti ve model performansının test edilmesinde kullanılan test setine ayırmak için kullanılmıştır.
- from sklearn.linear_model: Veriler arasındaki ilişkileri doğrusal bir düzlemde modelleyen algoritmaları içerir. Bu çalışmada bu kütüphaneden Logistic Regression kullanılmıştır.
- from sklearn.naive_bayes: Sklearn kütüphanesinden Naive Bayes algoritması kullanılmıştır.

- from sklearn.svm: Sklearn kütüphanesinden Linear SVM algoritması kullanılmıştır.
- Sklearn.metrics (classification_report, confusion_matrix): Modelin genel başarısının yanında precision, recall, f1-score gibi detaylı performans analizi ve confusion matrix için kullanılmıştır.
- lime.lime_text.LimeTextExplainer: Modelin bir metine hangi kelimelere dayanarak AI ve Human dediğini gösteren LIME analizinde kullanılmıştır.
- sklearn.pipeline.make_pipeline: TF-IDF vektörleştiricisi ve Linear SVM modelini tek bir pipeline içine yerleştirir. LIME analizinde ham veriler ile işlem gerçekleştirilemediğinden vektörleştirme ve modele vermenin tek bir komut ile gerçekleştirilmesi için kullanılmıştır.
- IPython.display (display, HTML): LIME analizindeki renkli sonuçları Colab üzerinde interaktif ve görsel olarak gösterebilmek için kullanılmıştır.

Dataset Splitting (Veri Bölünme Şekli)

Veri seti %80 Eğitim Seti %20 Test Seti olacak şekilde ikiye ayrılmıştır. Bu işlem esnasında stratify parametresi kullanılarak her iki kısmın AI ve Human sınıflarından eşit örnek içermesi amaçlanmıştır. (Stratification)

Model Eğitiminde Kullanılan Hiperparametreler:

Bu çalışmada, Logistic Regression model eğitiminde solver = saga parametresi kullanılarak eğitimin daha hızlı gerçekleştirilmesi sağlanmıştır. Multinomial Naive Bayes modeli eğitiminde alpha = 0.1 parametresi kullanılarak Laplace Smoothing işlemi gerçekleştirilmiştir. Bu parametrenin kullanılma amacı olasılık çarpımına dayanan Naive Bayes modelinde karşılaşılan Zero Probability problemidir. Bu problemi ortadan kaldırmak için kullanılmıştır. Linear SVM modeli eğitiminde random_state = 42 parametresi ile aynı veri seti üzerinde eğitimin tekrarlanması gereken durumlarda her eğitim sonucunun aynı olmasını, tesadüfi başarıların oluşmamasını sağlamak için kullanılmıştır.

Ek olarak, Logistic Regression ve Linear SVM modellerinde max iterasyon tanımlaması yapılmıştır. Bu iki algoritma optimizasyon tabanlı çalışmaktadır. Yani en iyi sonucu (minimum hata) bulana kadar deneme yanılma yolu ile kendilerini güncellemektedirler. Ama Multinomial Naive Bayes algoritmasında max iterasyon tanımlaması yapılmamıştır. Bunun sebebi Naive Bayes'in olasılık tabanlı bir algoritma olmasıdır. Bu algoritma veriyi bir kez taramakta ve sözlükteki kelimelerin her sınıfta kaç kez geçtiğini saymaktadır. Bayes Teoremini kullanarak olasılıkları çarpmakta ve doğrudan sonuca ulaşmaktadır.

RESULTS AND DISCUSSIONS

Model Eğitim Sonuçları

Model	Accuracy	Precision	Recall	F1-Score
-------	----------	-----------	--------	----------

Logistic Regression Model	%99,59	%99,62	%99,49	%99,59
Multinomial Naive Bayes Model	%97,14	%97,09	%96,76	%96,92
Linear SVM Model	%99,90	%99,91	%99,87	%99,89

Yukarıdaki tablo incelendiğinde tüm metrikler için modellerin başarı sıralaması şu şekilde olmuştur:

Linear SVM --> Logistic Regresyon --> Multinomial Naive Bayes

En yüksek başarının Linear SVM ve Logistic Regression modellerinden elde edilmesinin sebebi bu iki algoritmanın optimizasyon tabanlı çalışmasıdır. Bu iki algoritma en iyi sonucu bulana kadar denemeler yapma mantığına sahiptir. Ama Multinomial Naive Bayes’e bakıldığında bu algoritma olasılık çarpımı mantığına sahiptir. Bağımsızlık ilkesini savunur. Kelime sıklığı üzerinden bir tahmin yapar. Metin içerisindeki kelimelerin sıralanışını ve hangi kelimelerin bir arada kullanıldığını incelemeyi, bunlara bakarak bir tahminde bulunmaz. Model vektörleştirme kısmında tanımladığımız ngram_num (1,2) yapısı ile model aslında ikili kelime gruplarını da görüyor olsa da sadece bunların metindeki olasılıksal dağılımına bakar. Bu sebeple en düşük başarı Naive Bayes’de elde edilmiştir. Buna rağmen bu algoritma veriyi tek seferde incelediğinden hesaplama hızı ve maliyeti açısından oldukça verimlidir ve elde edilen başarı da kabul edilebilir düzeydedir.

Linear SVM ve Logistic Regression karşılaştırıldığında en yüksek başarının Linear SVM’de elde edilmesinin sebebi, TF-IDF ile vektörleştirilmiş verinin yüksek boyutlu uzayda genellikle doğrusal olarak çok iyi ayrışabilmesidir. Linear SVM de bu mantık ile çalışır. Ek olarak SVM sınıflar arası mesafeyi maximize (margin) ederek çalıştığından sınıflar arası en keskin sınır bu algoritma ile çizilebilmektedir.


Modeller eğitim sonrası veri seti dışından seçilen insan tarafından ve AI tarafından yazılan iki metin üzerinde test edilmiştir. Bu test sonucunda, Logistic Regression modeli insan tarafından yazılmış metne “%91,77” güven skoru ile insan derken AI tarafından yazılmış metne “%99,44” güven skoru ile AI demiştir. Multinomial Naive Bayes modeli ise insan tarafından yazılan metne “%82,16” güven skoru ile insan derken AI tarafından yazılan metne “%98,68” güven skoru ile AI demiştir. Son olarak Linear SVM modelinde diğer iki modelden farklı olarak “predict_proba” yerine “decision_function” kullanılmıştır. Bu sebeple test sonuçları yüzdeler olarak değil negatif,pozitif sayılar cinsinden elde edilmiştir. Linear SVM modeli verileri uzayda göstererek onları doğrusal bir düzlem ile ayırma mantığında çalışır. Test işleminde elde edilen değerler metnin sınıra (yani “0” a) olan uzaklığını göstermektedir. Metin için elde edilen değer sınırdan

ne kadar uzak ise model kendine güvenerek, yüksek güven skoru ile tahminini gerçekleştirmiş olmaktadır. Yapılan test işleminde model insan tarafından yazılmış metne -0.5751 güven skoru ile insan derken AI tarafından yazılan metne 2.1325 güven skoru ile AI demiştir.

Genel olarak üç modelin de test işlemi aşamasındaki tahminleri incelendiğinde AI tarafından yazılan metinlere daha kendinden emin yüksek güven skoru ile AI dediği gözlemlenmiştir. Bu durum modellerin AI tarafından yazılan metinleri daha kolay ayırt edebildiğini göstermiştir.


En yüksek başarıyı elde ettiğimiz Linear SVM modelinin Confusion Matrix, Precision-Recall Grafiği ve F1-Score Grafiği aşağıda gösterilmektedir.

Confusion Matrix



Bu matrix incelendiğinde modelin AI ve Human sınıflarını iyi bir şekilde ayırabildiği görülmektedir. Gerçek sınıfın AI olduğu metinlerde modelin Human tahmin ettiği örnek sayısı 85 olarak gözlemlenirken, tam tersi gerçek sınıfın Human olduğu metinlerde modelin AI tahmin ettiği örnek sayısı 12 olarak gözlemlenmiştir. Bu durum veri setindeki AI tarafından yazılan metinlerin insan eğiliminin, insan tarafından yazılan metinlerdeki AI eğiliminden daha yüksek olduğunu göstermektedir.


Precision-Recall Grafiği



Precision-Recall Grafiği, çalışma içeriği “yapay zeka ile insan metinlerinin ayrıştırılması” baz alınarak, Sınıf 1 olarak tanımlanan AI verileri kullanılarak oluşturulmuştur. Sınıf bazlı oluşturulmamasının, her iki sınıfta gösterilmemesinin sebebi modelin iki sınıfta da yüksek başarı elde etmesi sebebi ile çizgilerin üst üste binecek olması ve okunmasının zorlaşacak olmasıdır. Grafik incelendiğinde grafiğin sağ üst köşesinin boşluksuz, alanı tam dolduruyor olması modelin Precision ve Recall olmak üzere iki metrikte de ödün vermediğini ve oldukça yüksek başarı elde ettiğini göstermektedir. Ek olarak oldukça yüksek çıkan AP (Average Precision) Skoru ($AP = 1.0000$) modelin farklı güven skorlarında dahi oldukça başarılı tahminler yapabildiğini göstermektedir.


Sınıf Bazlı Performans Karşılaştırması Grafiği

Aşağıdaki grafikte Linear SVM modelinin sınıf bazlı performans karşılaştırması görülmektedir. Mavi renkli sütunlar Human'ı temsil ederken diğer renk ile gösterilen sütunlar AI'ı temsil etmektedir. Precision değeri incelendiğinde modelin AI tarafından yazılan metinleri insan tarafından yazılanlara göre daha doğru bir şekilde tahmin edebildiği gözlemlenmektedir. Recall değeri incelendiğinde modelin gerçekten insan tarafından yazılan metinleri AI tarafından yazılan metinlere göre daha iyi bir şekilde yakalayabildiği görülmüştür. Son olarak F1-Score değerleri incelendiğinde modelin Human ve AI sınıfları için başarı oranlarının birbirine oldukça yakın olduğu ama Human sınıfında çok az bir fark ile modelin daha başarılı olduğu fark edilmiştir.



Özellik Önemi Analizi (Feature Importance Analysis)

En yüksek doğruluk elde edilen Linear SVM modeli üzerinde gerçekleştirilen öznitelik analizi ile modelin bir metne AI ve Human demesinde en çok etkili olan ilk 20 kelime listelenmiştir. Aşağıda bu liste gösterilmektedir.



Hata Analizi (Error Analysis)

Her bir model için ayrı ayrı hata analizi gerçekleştirilmiştir. Bu analiz sürecinde modellerin toplam hata miktarı, gerçekte AI olan ama modelin Human dediği metin sayısı ve tam tersi gerçekte Human olan ama modelin AI dediği metin sayısı hesaplanmıştır. Modelin hata yaptığı ilk on metin ve güven skorları yazdırılarak incelenmiştir.

Yapılan bu analiz sonucunda modellerin düşük güven skorları ile bu hataları yaptığı gözlemlenmiştir. Hatalı metinler incelendiğinde bunların insan tarafından yazılmış ama dilbilgisi açısından oldukça düzgün ve akademik metinler olduğu aynı şekilde AI tarafından yazılmış ve yazım yanlışlarının olduğu günlük ifadelerin kullanıldığı metinler olduğu fark edilmiştir. Bu durum model tarafından AI ve Human sınıflarının genel özelliklerinin (AI tarafından yazılan

metinler daha resmi, dil bilgisine uygun oluşturulmuş olurken insan tarafından yazılan metinler daha günlük olmakta ve yazım yanlışları içermektedir.) anlaşıldığını, modelin ayırt edici özellik olarak resmiyet ve dil bilgisi kurallarına odaklandığını ve istisnai durumlar ile karşılaştığında hatalar yapabildiğini göstermiştir.

Ayrıca bu incelemeler sonucunda hata sıralamasında en yüksek hatayı yapan modelin Multinomial Naive Bayes olduğu, en düşük hatayı yapan modelin Linear SVM olduğu görülmüştür. Her modelin gerçekte AI tarafından yazılan metinlere Human deme oranının gerçekte Human tarafından yazılan metinlere AI deme oranından daha yüksek olduğu gözlemlenmiştir.


Ek olarak üç modelinde hatalı tahminde bulunduğu metin sayısı hesaplanarak ilk beş metin incelenmiştir. Bu aşama üç modelin ortak zayıf noktalarının görülmesi açısından önemlidir.

Açıklanabilir AI Metodu (Explanaible AI Method)

Açıklanabilir AI methodu olarak LIME tercih edilmiştir. Bu aşamada Hata Analizi aşamasında incelenen, üç modelinde hatalı tahmin yaptığı ve bize daha çok bilgi verebilecek metinlerden ikisi seçilmiş ve iki metin üzerinde LIME analizi gerçekleştirilmiştir.



İlk metin gerçek etiketin AI olduğu ama üç modelinde Human olarak tahmin ettiği metindir. Bu metin incelendiğinde, modelin Human ve AI olarak metin sınıfını belirlemesinde etkili olan kelimeler ve bu kelimelerin tahmin üzerindeki etkisi koyu ve açık tonlamalar şeklinde görülmektedir. Kelimeler incelendiğinde “effect” kelimesinin modelin Human demesinde yüksek bir etkiye sahip olduğu görülürken “like” kelimesinin de modelin AI demesinde yüksek bir etkiye sahip olduğu görülmektedir. Tüm kelimelerin modele etkileri toplandığında Human tarafında 1,35 skoru elde edilirken AI tarafında 1,13 skoru elde edilmiştir. Bu skorlara göre model 0,16 düşük güven skoru ile tam emin olamayarak Human tahmininde bulunmuştur.



İkinci metin gerçek etiketin Human olduğu ama üç modelin de AI dediği bir metindir. Bu metin

incelendiğinde aynı şekilde modelin Human ve AI şeklinde metinleri sınıflandırmasında etkili olan kelimeler ve etki düzeyleri gösterilmektedir. Etki düzeyleri toplandığında Human tarafında sayıca elde edilen skor 1,17 olurken AI tarafında skor 0,93 olarak karşımıza çıkmaktadır. İnsan tarafındaki kelimelerin bireysel ağırlık üstünlüğüne rağmen model metni görüldüğü gibi 0,07 gibi oldukça düşük bir güven skoru ile AI olarak sınıflandırmıştır. Bu aslında şunu göstermektedir, insan tarafındaki kelimelerin bireysel ağırlıkları yüksek olsa da AI tarafındaki kelimelerin sayıca çok olması ve metin geneline yayılarak metnin resmi üslubunu temsil etmesi toplam karar ağırlığını oldukça küçük bir fark ile AI tarafına kaydırmıştır.

CONCLUSION

Bu çalışmada, insan ve yapay zekâ tarafından üretilen metinlerin sınıflandırılması problemi ele alınmış ve farklı makine öğrenmesi algoritmaları kullanılarak karşılaştırmalı bir analiz gerçekleştirilmiştir. Uygulanan veri ön işleme ve TF-IDF tabanlı özellik çıkarımı yöntemleri sayesinde metin verisi modellemeye uygun hale getirilmiş ve yüksek başarı oranları elde edilmiştir.

Elde edilen sonuçlar doğrultusunda, Linear SVM modelinin %99,90 doğruluk oranı ile en başarılı model olduğu görülmüştür. Logistic Regression modeli benzer şekilde yüksek performans gösterirken, Multinomial Naive Bayes modelinin daha düşük doğruluk oranına sahip olduğu ancak hesaplama maliyeti açısından avantajlı olduğu gözlemlenmiştir. Bu durum, optimizasyon tabanlı modellerin yüksek boyutlu metin verilerinde daha etkili olduğunu ortaya koymaktadır.

Gerçekleştirilen hata analizleri, modellerin genellikle dil bilgisi açısından düzgün ve resmi metinleri yapay zekâ çıktısı olarak değerlendirme eğiliminde olduğunu göstermiştir. Aynı şekilde, daha gündelik ve hata içeren metinlerin insan tarafından yazılmış olarak sınıflandırıldığı gözlemlenmiştir. Bu bulgular, modellerin metinlerin yapısal ve dilsel özelliklerine odaklandığını ortaya koymaktadır.

Ayrıca, LIME analizi ile model kararlarının açıklanabilirliği artırılmış ve belirli kelimelerin sınıflandırma üzerindeki etkisi detaylı bir şekilde incelenmiştir. Bu sayede, modelin yalnızca yüksek performans göstermesi değil, aynı zamanda yorumlanabilir olması da sağlanmıştır.

Sonuç olarak, bu çalışma yapay zekâ tarafından üretilen metinlerin tespit edilmesinde makine öğrenmesi yöntemlerinin oldukça etkili olduğunu göstermektedir. Gelecek çalışmalarda, derin öğrenme tabanlı modellerin (örneğin Transformer tabanlı yaklaşımlar) kullanılması, daha büyük ve dengeli veri setleri ile çalışılması ve çok dilli analizlerin yapılması önerilmektedir. Bu tür geliştirmeler, model performansını daha da artırarak gerçek dünya uygulamalarında daha güvenilir sistemlerin oluşturulmasına katkı sağlayacaktır.

